Una prima de riesgo para cada periodo de póliza, construida y contrastada con IA

AI Hackathon IAA 2026 · Parte 1, mercado establecido · Manuel Rodríguez, equipo individual (Kaggle: manoloriveros) · Versión del 20 de octubre de 2026 · Copia en español del informe que se entrega en inglés

La respuesta en una página

El reto pide estimar, para cada periodo de póliza de 2025 en autos particulares, edificios y contenidos del hogar, el coste último esperado de los siniestros ocurridos en el periodo, neto de franquicias y recobros y sin siniestros rechazados. Es la prima de riesgo, antes de gastos y márgenes. El concurso la mide con el D^2 Tweedie de potencia 1,5, que indica qué fracción de la desviación explica el modelo frente a cobrar a todos el coste medio. Como más del 90 % de los periodos no tiene siniestros, valores entre 0,10 y 0,15 ya separan bien el riesgo. Los datos son sintéticos y los importes van en una unidad ficticia (CU).

0,12996
puntuación pública del modelo final; primer puesto del tablero público entre 19 equipos (consulta del 19 de octubre)

0,138
D^2 en 2024, fuera de muestra, frente a 0,071 de una tasa constante por ramo

626.639
periodos de 2025 predichos en tres ramos, con diez controles de formato e integridad

217
aportes de tres líneas de IA en un foro común durante 54 horas, con hipótesis preinscritas

Construimos el modelo en seis etapas (Figura 1). Reconstruimos los datos con ocho reglas reversibles y asignamos cada siniestro al único periodo que lo cubre. Después llevamos el coste observado a nivel último: estimamos qué parte de cada peligro de 2024 seguía sin reportarse y la incorporamos a la exposición de entrenamiento, de modo que el ajuste por siniestros no reportados (IBNR) entra una sola vez. El modelo final, que llamamos Mezcla por peligro, combina en cada ramo modelos del coste total con modelos de frecuencia por severidad por peligro, y fija el nivel de 2025 con los años 2023 y 2024 como contraste fuera de muestra.

La IA intervino en todas las etapas, sobre todo para confrontar posturas. Tres líneas de trabajo independientes, apoyadas en dos asistentes de IA, publicaban sus hipótesis antes de calcularlas y también sus fracasos; un enjambre de agentes de validación auditaba el proyecto cada seis horas. Autoricé las reglas de datos y los envíos a Kaggle, y aprobé el modelo final.

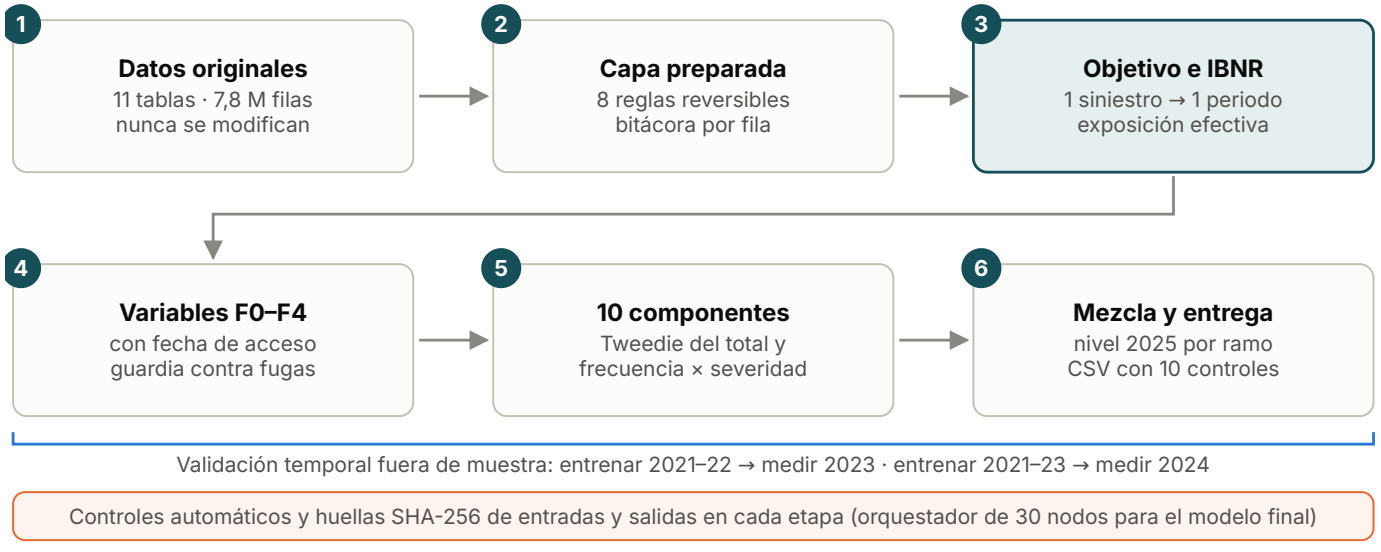


Figura 1 El flujo actuarial. La etapa 3 traslada el retraso de reporte a la exposición de entrenamiento; las etapas 4 a 6 se validan con años completos fuera de muestra y cada paso deja huellas SHA-256 comprobables.

Criterio de la rúbrica	Dónde se responde
Rendimiento y adaptación (40 %)	Puntuación pública y local, tratamiento de datos, límites; plan para el mercado nuevo
Uso eficaz de la IA (25 %)	Etapa por etapa: qué hizo la IA, cómo se verificó y qué cambió gracias a la confrontación
Confianza, validación y controles (20 %)	Validación temporal, 12 experimentos preinscritos con backtesting del IBNR, 45 casos de control, un reentrenamiento completo que reconstruye byte a byte el archivo entregado
Comunicación y documentación (15 %)	Este informe, el video, el repositorio versionado y un panel sin conexión con las mismas cifras, en español o inglés (`docs/entrega/panel_modelo.html`)

Datos: qué corregimos y qué dejamos como incertidumbre

Los once Parquet originales (7,8 millones de filas) se conservan intactos. Todo cambio vive en una capa derivada, con bitácora por fila y posibilidad de revertirlo. La auditoría inicial revisó las 105 columnas y encontró problemas que habrían distorsionado las tasas:

Problema encontrado	Filas	Tratamiento
Los identificadores de cliente de autos perdieron los ceros iniciales	123.664	Relleno a ocho dígitos; se recupera el cruce con el maestro
Parte de la exposición estaba en días o en base 360, no en años	14.229	Días cubiertos entre 365, la convención de todo 2025
Capitales asegurados con saltos de unas mil veces dentro de una póliza	2.073 + 1.454	División entre mil cuando la historia de la póliza o una prueba de prima lo respalda; 149 se apoyan solo en la prueba de prima y quedan como incertidumbre declarada
Mayúsculas mezcladas en categorías y edad medida en fechas distintas	700.210 · 2.936	Unificación; la edad se calcula al inicio del periodo (cambio de convención, no corrección de errores)
Siniestros duplicados, idénticos salvo el identificador	604	Se excluye la copia
Rechazos de renovación con sucesor y siniestros previos al historial	12.041 · 413	Solo se marcan para auditoría; nunca entran como predictores

Dos implementaciones independientes confirman la capa preparada: un segundo asistente recalculó las ocho reglas desde los originales con código propio (41 de 41 comprobaciones) y un productor alternativo reconstruyó las once tablas byte a byte, con 148 millones de celdas comparadas y ninguna diferencia.

Del coste observado al coste último

Para aprender hace falta una etiqueta por periodo. Asignamos cada siniestro por póliza, ramo y fecha de ocurrencia dentro del periodo cubierto, sin usar la fecha de reporte. Tras excluir las copias exactas, los rechazados y los siniestros anteriores al historial de su póliza (que se concilian aparte), quedan 160.432 de los 163.150 registros como siniestros aceptados, cada uno en un solo periodo; ninguno queda ambiguo. La etiqueta T0 suma el incurrido de esos siniestros menos los recobros; los pagos ya vienen netos de franquicia, así que no se descuenta dos veces.

T0 aún no es el coste último, porque al cierre de 2024 faltan siniestros por reportar. Un chain-ladder de conteos por peligro estima qué parte de la exposición de 2024 ya está «vista»: solo el 56 % en lesiones corporales de autos y el 66 % en hundimiento de edificios, frente a 94–98 % en los demás peligros (Figura 2). Entrenamos con esa exposición efectiva como offset y predecimos 2025 con la exposición nominal. El modelo aprende así tasas a nivel último sin aplicar el IBNR dos veces.

La Figura 3 muestra por qué importa. El coste observado de autos en 2024 (454 CU por año-exposición) parece una caída brusca; con el IBNR estimado sube a 584, en línea con 2021–2023, y la predicción de 2025 (595) continúa esa tendencia. Las reservas de caso de los siniestros abiertos se toman a su valor del cierre; con una única valoración no se puede demostrar que sean suficientes, por eso medimos su sensibilidad más abajo.

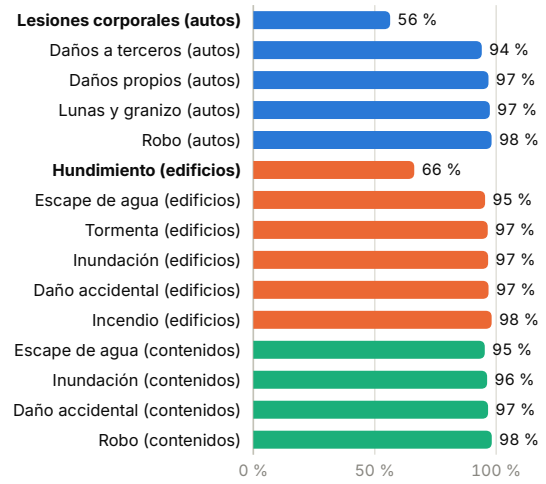


Figura 2 Parte de la exposición de 2024 cuyos siniestros ya se han reportado, por peligro.

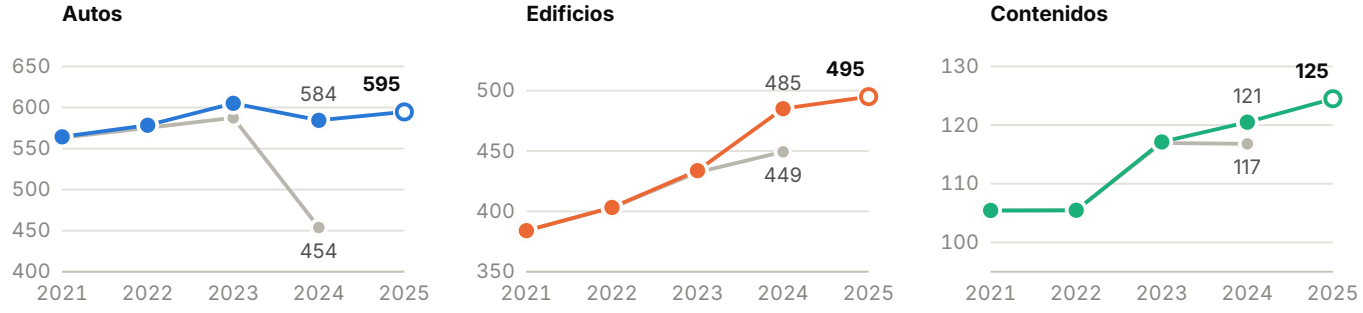


Figura 3 Prima de riesgo por año-exposición, en CU. Gris: coste observado (T0). Color: con el IBNR estimado. Círculo hueco: predicción del modelo final para 2025.

La Mezcla por peligro: un modelo final con diez componentes

Ningún modelo único dominó en los tres ramos. Los modelos del coste total con distribución Tweedie (LightGBM y CatBoost) captan bien las interacciones entre variables; los de frecuencia por peligro multiplicada por la severidad separan mecanismos distintos (un incendio no se parece a una fuga de agua) y permiten proyectar la tendencia de severidad de cada peligro. El modelo final pondera ambos tipos por ramo (Figura 4). Los cambios se juzgaron con criterios escritos antes de calcularlos, en 2023 y en 2024, con todas las pérdidas y sin las más extremas; los criterios variaron entre líneas de trabajo, y el modelo final fue un ensayo que autoricé sin que pasara todos los filtros internos.

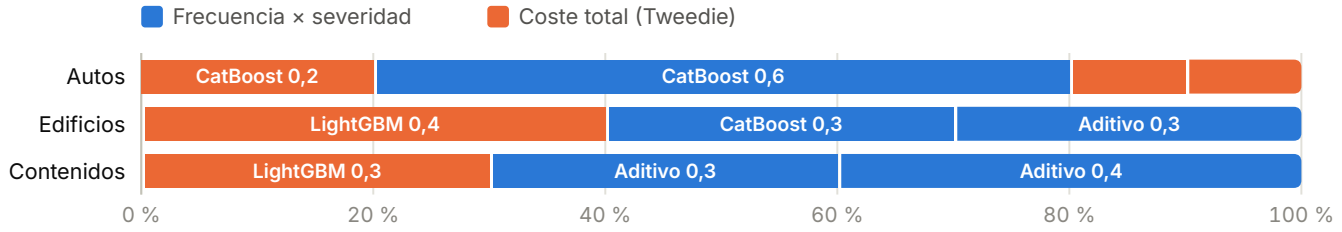
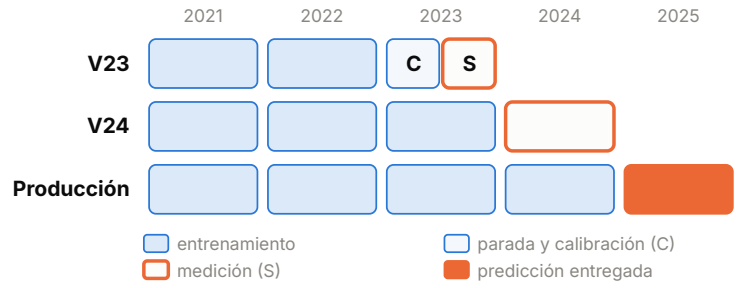


Figura 4 Composición del modelo final. Azul: frecuencia por peligro × severidad. Naranja: coste total con Tweedie. El anexo detalla cada componente.

El nivel de 2025 se fija por ramo con el factor que minimiza la desviación Tweedie, f = Σ(y/√μ) / Σ√μ, promediado entre los cortes de 2023 y 2024; el anexo detalla los factores. Los componentes cuyo nivel es inestable entre cortes aportan el reparto del riesgo, pero no fijan el nivel. En autos y edificios la severidad de cada peligro se proyecta un año con su tendencia, acotada a ±15 %. El total de 2025 es de 212,0 millones de CU, y autos tiene la tasa más alta por año-exposición (594,6 CU).

Cómo lo validamos

Validamos como se usaría la tarifa: ajustar con años pasados y medir en un año completo posterior (Figura 5). Ningún coste de 2025 entra en el ajuste; la regla de nivel y la normalización de tasas sí usan las covariables y las predicciones de la cartera de 2025.



C y S: mitades de clientes de 2023 para calibrar y para medir.
Etiquetas valoradas al 31-12-2024: validación temporal aproximada.

Figura 5 Tres cortes temporales. Producción reentrena con 2021–2024 y predice 2025.

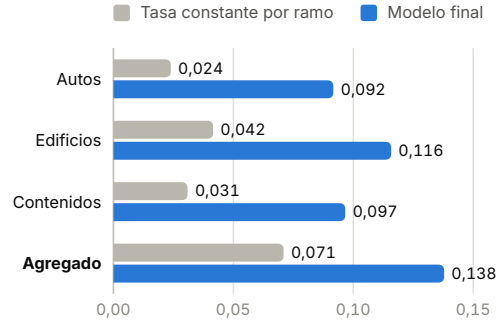


Figura 6 D^2 de 2024 por ramo: el modelo final frente a una tasa constante por ramo.

En 2024 el modelo final explica casi el doble de desviación que la tasa constante por ramo (0,138 frente a 0,071) y mejora cada ramo por separado. También ordena bien el riesgo: el 10 % de periodos con mayor coste predicho reúne entre el 29 % y el 34 % del coste observado, y en cada decil lo observado sigue a lo predicho (Figura 7).

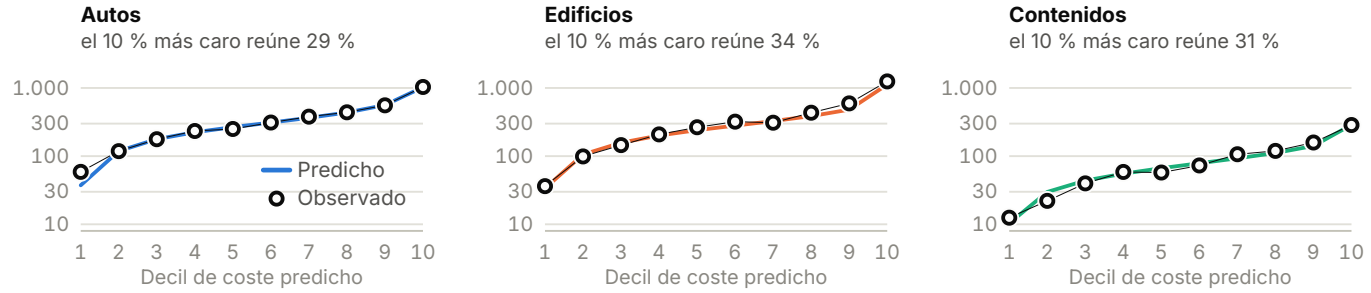


Figura 7 Coste medio por periodo en 2024 por decil de coste predicho (escala logarítmica). Línea: predicho. Círculos: observado.

Con las reservas de caso de los abiertos multiplicadas por 0,75 o por 1,25, el D^2 de 2024 baja de 0,1379 a 0,1372 y el modelo conserva su ventaja frente a las alternativas, pero los mismos escenarios mueven el nivel de 2025 hasta un 6,8 %. En edificios, el coste de 2024 superó en un 10 % lo predicho con el factor de 2023, por eso el nivel de 2025 promedia los dos factores. La página 5 resume los experimentos que pusieron a prueba estos resultados después de la elección.

Cómo trabajó la IA y cómo la pusimos a prueba

Organizamos el trabajo para que la IA no se validara a sí misma (Figura 8). Dos asistentes de IA, Claude y Codex, trabajaron en tres líneas: modelado, alternativas creativas y contraste. Ninguna podía usar predicciones de otra sin autorización expresa, las hipótesis se publicaban con su criterio de aceptación antes de calcularse y los resultados adversos se registraban igual que los favorables. En 54 horas el foro reunió 217 aportes; más de un tercio fueron preinscripciones o resultados adversos.

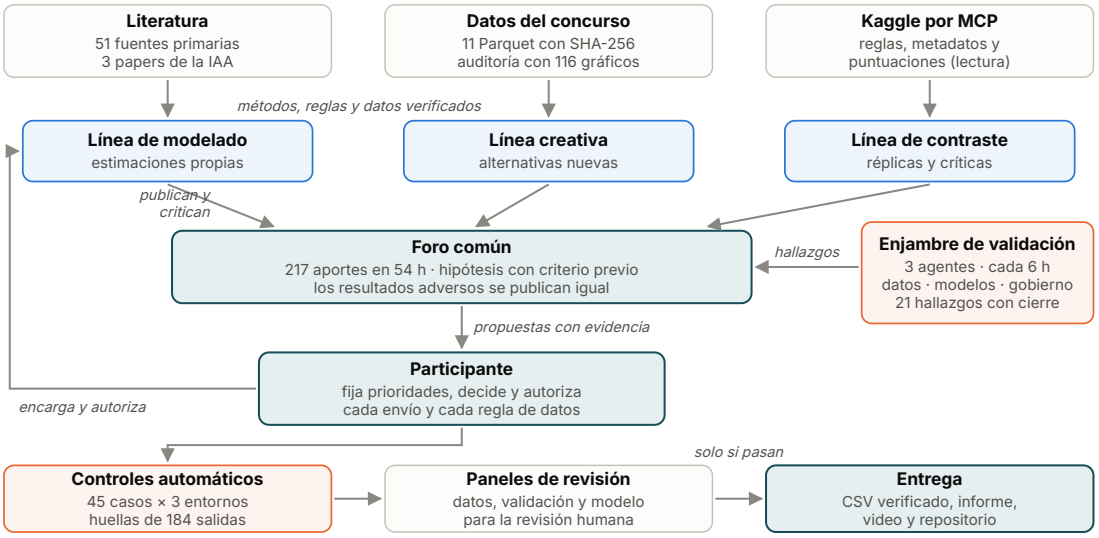


Figura 8 Organización de la IA. El participante encarga y autoriza; las líneas publican en el foro; un enjambre de tres agentes audita cada seis horas; nada llega a la entrega sin pasar los controles automáticos.

Etapa	Qué hizo la IA	Cómo lo verificamos
Datos y objetivo	Auditó 105 columnas; halló claves sin ceros, exposición en días, capitales ×1000 y 604 duplicados; asignó siniestros y estimó el IBNR	Recálculo independiente (41/41), reconstrucción byte a byte y dos algoritmos de asignación que coinciden
Variables	Contrato de disponibilidad por columna; detectó una variable que mide el siniestro del propio periodo (D^2 individual 0,43; las demás, menos de 0,04)	Exclusión por código con una guardia de predictores
Metodología	Dos búsquedas con 51 fuentes primarias cotejadas con DOI y arXiv, más tres papers de la IAA	Se descartó, por falta de evidencia, una mejora del 17 % que proponía otra herramienta de IA
Modelado y diagnóstico	44 contrastes numerados, preinscripciones y una batería preinscrita de 12 experimentos de sensibilidad	Intervalos por cliente, dirección y región; escenarios de reserva, nivel y capital
Pruebas y gobierno	Orquestador de 30 nodos con huellas de 184 salidas; enjambre de validación con 21 hallazgos	Un validador detectó que el paquete daba «éxito» con archivos faltantes: corregido y probado con 36 casos adversos

El hallazgo que más cambió el resultado se ve en la Figura 9. Varias propuestas mejoraban la validación local de 2024 y aun así bajaban en el tablero público. Una línea mostró que la inversión venía de unos pocos siniestros extremos y otra lo convirtió en un criterio medible: el D^2 sin el 0,5 % de pérdidas mayores ordena a los candidatos casi igual que el público (correlación de rangos 0,83, frente a 0,49 con todas las pérdidas). Con esa lectura se retiró una forma de hogar que dependía de la cola y se exigió mejorar también el «cuerpo», sin quitar la cola de la métrica. Los dos envíos siguientes marcaron el máximo público; el segundo es el modelo final. La misma confrontación rebajó a hipótesis una afirmación excesiva sobre las reservas.

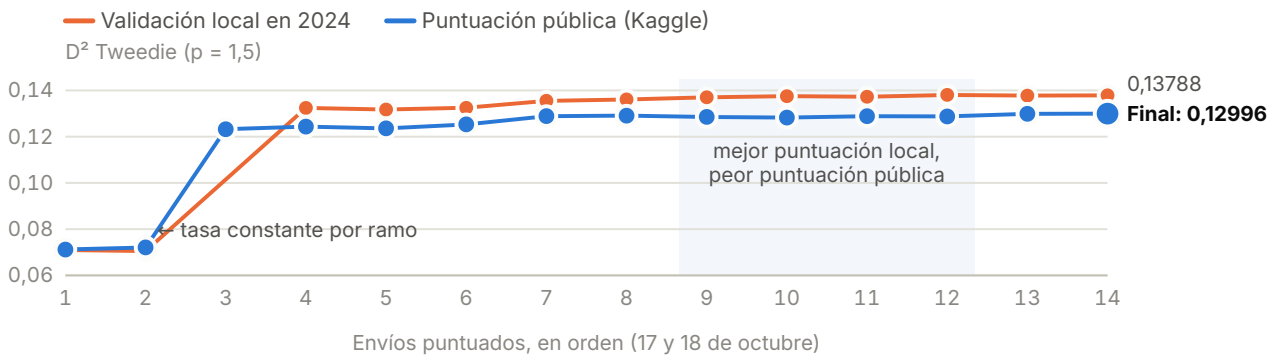


Figura 9 Camino hasta el modelo final: los 14 envíos puntuados, en orden. La zona sombreada marca las propuestas con mejor puntuación local y peor puntuación pública.

Controles, reproducibilidad y responsabilidad humana

Capa	Control	Resultado
Datos originales	Huellas SHA-256 de los once Parquet y reconstrucción independiente	11 de 11 idénticos; 0 diferencias en 148 millones de celdas
Objetivo, exposición y variables	Conciliación de asignación, T0, reservas y exposición; contrato de disponibilidad por columna	18 de 18 y 25 de 25 controles
Paquete	9 casos nominales y 36 adversos lanzados desde la consola	45 de 45 en la nube, en una máquina virtual y en Windows
Entrega	Columnas, filas, orden, identificadores, valores positivos y SHA-256 del recibo	10 de 10 controles

Con `python reproducir.py mezcla --objetivo=S30` el CSV final se regenera desde los componentes guardados con el SHA-256 que recibió Kaggle (S30 es el identificador del modelo en el código). Reentrenar toda la receta desde los originales lo reconstruyó byte a byte (162 de 181 huellas intermedias iguales y el resto dentro de 3,9e-15), y una réplica desde los 436 estimadores guardados, sin reajustes, dio 194 de 194 salidas idénticas. Lo hizo el mismo flujo, así que no es una reproducción independiente.

La responsabilidad es humana. Soy actuario, con 13 años de experiencia en actuaría y supervisión. Autoricé las reglas de datos y los envíos, fijé la prioridad de diseño (un flujo que otro actuario pueda entender, reproducir y adaptar), aprobé el modelo final el 18 de octubre y el 20 lo confirmé como definitivo, con lo que cerré la parte 1; la selección manual en Kaggle, aún pendiente, me corresponde. Acepté las correcciones técnicas del paquete y de la captura solo en ese alcance, y declaré como limitaciones la reproducción independiente y la suficiencia de las reservas. Ninguna verificación, de la IA o mía, es revisión independiente, porque participé en el desarrollo: cada uno de los 12 hallazgos abiertos indica qué revisor necesita.

Experimentos de validación y límites que dejan

Tras la elección, once experimentos preinscritos, entre ellos un backtesting del IBNR, y un análisis de reservas pusieron a prueba el modelo final; el anexo los detalla, junto con un duodécimo que no hizo falta correr. Reutilizan los cortes de 2023 y 2024: miden estabilidad, no rendimiento independiente, y cada resultado adverso queda como límite. Dos límites no dependen de un experimento: esos cortes eligieron el modelo, y las fechas de las variables al cotizar esperan la confirmación del dueño de los datos.

Experimento	Resultado	Qué hacemos
Reservas ×0,75 y ×1,25; acotación con materialidad del 1 %	El D^2 solo pasa de 0,1379 a 0,1372, pero un error del 3,7 % en las reservas de caso de autos (4,0 % en edificios) ya mueve el nivel de 2025 un 1 %	Incertidumbre material en los tres ramos, declarada como limitación; hacen falta valoraciones sucesivas
Backtesting del IBNR en tres cortes anteriores	Fuera de su criterio en 6 o 7 de 15 peligros por corte, sobre todo en los de pocos avisos; IBNR de lesiones del año recién cerrado sobrestimado en 2022 y 2023 (+20,1 % y +7,9 %)	Con los recobros ausentes en los abiertos, un escenario sitúa autos alto entre un 1,5 % y un 2,5 %: escenario declarado, no sesgo identificado, y sin aplicar
Nivel de 2025 desde dos cortes	Los factores de edificios (1,059 y 1,134) distan un 3,4 % de su media	Se promedian los dos cortes; recalibrar es lo primero en la semana 2
Influencia de clientes, semillas y pesos	Quitar 6 de 373.831 clientes invierte la ventaja sobre el mejor envío anterior; las semillas mueven el D^2 como mucho 0,00003; 0 de 40 conjuntos de pesos vecinos mejoran los dos cortes	La ventaja no es robusta y no se afirma equivalencia; los pesos están en una meseta
Los 149 capitales sin confirmación, sin dividir	Sus filas pasan a ser de 35 a 89 veces mayores; juntas pesan el 0,01 % del total predicho (24.668 CU)	Mantener la división; confirmarla con un actuario de hogar

Semana 2: cómo adaptaremos el modelo

En el mercado nuevo el modelo congelado será la referencia, con el mismo protocolo de preinscripción, foro y controles; cada diferencia decidirá la respuesta, y esta sección se reemplazará con lo observado:

Si cambia	Respuesta prevista
El contrato, las unidades o la exposición (moneda, convención de días, objetivo)	Reconstruir la capa preparada sin trasladar reglas que no tengan evidencia nueva
La mezcla de peligros o las colas	Reentrenar severidades por peligro; revisar el criterio de cuerpo y la regla de nivel
El patrón de reporte de los siniestros	Reestimar el chain-ladder por peligro antes de entrenar
Las variables disponibles o su fecha de captura	Actualizar el contrato por columna y la guardia de predictores
El rendimiento del modelo congelado (caída del D^2 o descalibración por decil)	Recalibrar primero; reconstruir solo si la recalibración no basta

Anexo, fuera de las cinco páginas calificables

Componentes y parámetros del modelo final

Ramo	Componente	Tipo	Peso
Autos	CatBoost Tweedie del coste total, cuatro semillas	Coste total	0,2
Autos	CatBoost Poisson por peligro × severidad GLM gamma con tendencia	Frecuencia × severidad	0,6
Autos	LightGBM Tweedie con variables F0 a F4	Coste total	0,1
Autos	LightGBM Tweedie con variables reducidas	Coste total	0,1
Edificios	LightGBM Tweedie con siete variables de cliente	Coste total	0,4
Edificios	CatBoost Poisson por peligro × severidad por capital con tendencia	Frecuencia × severidad	0,3
Edificios	Frecuencia aditiva por peligro × severidad por capital con tendencia	Frecuencia × severidad	0,3
Contenidos	LightGBM Tweedie	Coste total	0,3
Contenidos	Frecuencia aditiva por peligro × severidad LightGBM gamma	Frecuencia × severidad	0,3
Contenidos	Frecuencia aditiva por peligro × severidad GLM con covariables físicas	Frecuencia × severidad	0,4

Forma de la tasa: en autos exponente 1,09 sobre la dispersión de tasas y elasticidad de exposición 0,95; en contenidos elasticidad 0,95; edificios sin forma. Factores de nivel f (2023 / 2024 / media): autos 0,986 / 1,005 / 0,996; edificios 1,059 / 1,134 / 1,097; contenidos 1,078 / 1,092 / 1,085. Validación: entrenamiento con offset log(exposición efectiva); V23 entrena 2021–2022 y para el boosting en la mitad de calibración de 2023; V24 entrena 2021–2023 con las rondas de V23 × 1,15; producción entrena 2021–2024 con × 1,3. D^2 recalculado desde las predicciones guardadas: V23 0,14542 y V24 0,13788 (autos 0,09168; edificios 0,11580; contenidos 0,09665). Archivo entregado (identificador S30): 626.639 filas, SHA-256 fd9528e0b1ee4b674dea63834a97523fd4ddc743d1495a422ce31a2eb76e3bc5, envío Kaggle 57371361.

Experimentos tras la elección del modelo final

Once experimentos se escribieron con su hipótesis y su criterio de aceptación antes de calcular; el backtesting del IBNR se añadió a pedido del participante, con su propia preinscripción. Comparan el modelo final con el mejor envío anterior en la mitad de selección de 2023 y en el año 2024 completo, con el D^2 completo y el del cuerpo, y tratan como empate cualquier diferencia por debajo del piso de semillas. Un análisis preinscrito aparte acotó las reservas de caso con la materialidad del 1 % que el participante fijó antes de ver resultados.

Experimento	Pregunta	Resultado frente al criterio fijado
Influencia de clientes	¿Depende la ventaja de pocos clientes?	Sí: quitar 6 de 373.831 clientes la invierte en 2024, y 1 en 2023. Rechazada
Nivel por ramo	¿Es estable el nivel de 2025 entre los dos cortes?	No en edificios (1,059 frente a 1,134); autos dista un 0,9 % y contenidos un 0,7 % de su media. Rechazada en edificios
Reservas y recobros	¿Resisten el orden y el nivel?	La ventaja se mantiene con reservas ×0,75, ×1 y ×1,25; los recobros ausentes en los abiertos de autos bajarían su nivel un 0,75 %
Pesos vecinos	¿Hay pesos mejores cerca?	0 de 40 vecinos mejoran los dos cortes y los dos criterios. Meseta confirmada
Capitales sin confirmación	¿Es inmaterial la división entre mil?	No por fila: sin dividir, esas filas son de 35 a 89 veces mayores. Rechazada
Cohortes y segmentos	¿Es homogénea la ventaja?	Los segmentos adversos no se repiten entre cortes; el A/E regional de edificios correlaciona 0,22 entre años. Rechazada en parte
Piso de ruido	¿Es el piso de semillas menor que 0,0001?	Sí: las semillas mueven el D^2 como mucho 0,00003. Confirmada
Tendencia de severidad	¿Resiste la ventaja a otros escenarios de tendencia?	Sí, en todos los escenarios probados, con matices de atribución. Confirmada
Forma y elasticidad	¿Están en una meseta?	No: el D^2 se mueve entre 0,0002 y 0,0015 en ±0,02, pero ningún punto mejora los cuatro criterios
Reproducción	¿Se reproducen los componentes al reentrenar?	Dos LightGBM de hogar: 1.111.301 predicciones guardadas, bit a bit. Confirmada
Semilla nueva	¿Cuánto mueve una semilla nueva?	No ejecutado: ya lo cubren una corrida anterior de cinco semillas y la reproducción
Backtesting del IBNR	¿Predice el chain-ladder los avisos posteriores?	No en varios peligros: 6 o 7 de 15 fuera del criterio por corte (figura A1). En lesiones, el IBNR del año recién cerrado se sobrestimó un 20,1 % (2022) y un 7,9 % (2023); en junio de 2024 la proyección quedó un 7,5 % corta. Rechazada, con efecto acotado
Acotación de reservas	¿Cuánto error de reserva importaría?	Un 3,7 % en autos, un 4,0 % en edificios y un 9,0 % en contenidos mueven el nivel un 1 %; las estimaciones puntuales no sugieren reservas cortas, pero sus intervalos no las descartan. Incertidumbre material

Peligro (ramo)	Criterio	Corte dic. 2022	Corte dic. 2023	Corte jun. 2024
Daños propios (autos)	±10 %	+5 %	+4 %	0 %
Daños a terceros (autos)	±10 %	+4 %	+9 %	−3 %
Lesiones corporales (autos)	±20 %	**+22 %**	+7 %	−7 %
Robo (autos)	±10 %	**+33 %**	+9 %	**+14 %**
Lunas y granizo (autos)	±10 %	+6 %	**−23 %**	+1 %
Tormenta (edificios)	±10 %	**−18 %**	+9 %	+10 %
Inundación (edificios)	±10 %	−2 %	**−19 %**	**+90 %**
Escape de agua (edificios)	±10 %	+3 %	−9 %	**+14 %**
Hundimiento (edificios)	±20 %	−14 %	**+26 %**	−19 %
Incendio (edificios)	±10 %	**+34 %**	**−42 %**	**+23 %**
Daño accidental (edificios)	±10 %	**+31 %**	**+35 %**	−2 %
Robo (contenidos)	±10 %	**−11 %**	**+10 %**	**−22 %**
Escape de agua (contenidos)	±10 %	+3 %	−1 %	**−14 %**
Daño accidental (contenidos)	±10 %	+2 %	+9 %	−8 %
Inundación (contenidos)	±10 %	**+92 %**	−10 %	**+47 %**

Dentro de su criterio Fuera de su criterio

Error = (proyectado − reportado) / reportado. En negrita, los peligros de cola larga, con criterio ±20 %.

Figura A1 Backtesting del IBNR. El chain-ladder de reporte se reestimó con los datos disponibles en tres cortes anteriores; cada celda compara los avisos que proyectaba recibir después del corte con los reportados hasta diciembre de 2024. Las cifras del año recién cerrado que cita el texto comparan el IBNR de ese año con su reestimación con todos los datos.

Glosario breve

Término	Significado
D^2 Tweedie	1 menos el cociente entre la desviación Tweedie del modelo y la de predecir la media; 0 equivale a no saber nada y 1 a acertar cada periodo
T0	Incurrido neto observado al 31-12-2024 de los siniestros aceptados del periodo
IBNR	Siniestros ocurridos y aún no reportados al cierre
Exposición efectiva	Exposición nominal multiplicada, mes a mes, por la proporción de siniestros de ese peligro que ya se habría reportado
Cuerpo	La distribución sin el 0,5 % de periodos más costosos, usada solo como diagnóstico
Preinscripción	Hipótesis, datos y criterio de aceptación escritos antes de calcular

Referencias principales

- Smyth y Jørgensen (2002). Fitting Tweedie's compound Poisson model to insurance claims data. ASTIN Bulletin 32(1).
- Delong, Lindholm y Wüthrich (2021). Making Tweedie's compound Poisson model more accessible. European Actuarial Journal.
- Denuit, Charpentier y Trufin (2021). Autocalibration and Tweedie-dominance for insurance pricing with machine learning. Insurance: Mathematics and Economics.
- Henckaerts, Côté, Antonio y Verbelen (2021). Boosting insights in insurance tariff plans with tree-based machine learning methods. North American Actuarial Journal.
- Yang, Qian y Zou (2018). Insurance premium prediction via gradient tree-boosted Tweedie compound Poisson models. arXiv:1508.06378.
- Fissler, Lorentzen y Mayer (2023). Model comparison and calibration assessment. arXiv:2202.12780.
- Denuit, Sznajder y Trufin (2019). Model selection based on Lorenz and concentration curves, Gini indices and convex order. Insurance: Mathematics and Economics 89.
- Lindholm y Nazar (2024). On duration effects in non-life insurance pricing. European Actuarial Journal.
- Verbelen, Antonio, Claeskens y Crevecoeur (2022). Modeling the occurrence of events subject to a reporting delay via an EM algorithm. Statistical Science.
- Lindholm, Richman, Tsanakas y Wüthrich (2022). Discrimination-free insurance pricing. ASTIN Bulletin.
- Wüthrich y Merz (2023). Statistical Foundations of Actuarial Learning and its Applications. Springer.
- Goldburd, Khare, Tevet y Guller. Generalized Linear Models for Insurance Rating. CAS Monograph 5.
- IAA AI Task Force: Professional Considerations for Actuaries Interacting with Artificial Intelligence (2026); Artificial Intelligence Governance Framework (2025); Documentation of Artificial Intelligence Models or Systems (2025).

Procedencia de las cifras

Cada número de este informe sale de `docs/entrega/datos/cifras_entregables.json`, que guarda la ruta y el SHA-256 de cada fuente que lee y se regenera con `herramientas/cifras_entregables.py`; `herramientas/verificar_entregables.py` comprueba que el texto coincide con ese archivo. El foro completo (con identificadores sintéticos omitidos), el registro de decisiones y los recibos de cada envío se conservan como expediente de trabajo en `docs/expediente/` y `registro/`.