Una prima de riesgo para cada periodo de póliza, construida y contrastada con IA

La Mezcla por peligro · Manuel Rodríguez · equipo individual · Parte 1, mercado establecido

0,13016

puntuación pública de la entrega final, primer puesto entre 43 equipos en la tabla pública (22 de octubre)

0,138

D^2 de 2024 fuera de muestra, frente a 0,071 de una tasa constante por ramo

252

aportes de tres líneas de trabajo con IA en un foro común, en 125 horas

La tarea: el coste último esperado de cada periodo

626.639 periodos de autos, edificios y contenidos, aprendidos de 2.409.311 periodos de 2021–2024. Neto de franquicia y recobros; sin siniestros rechazados.

La mayoría de los periodos no cuesta nada

Autos

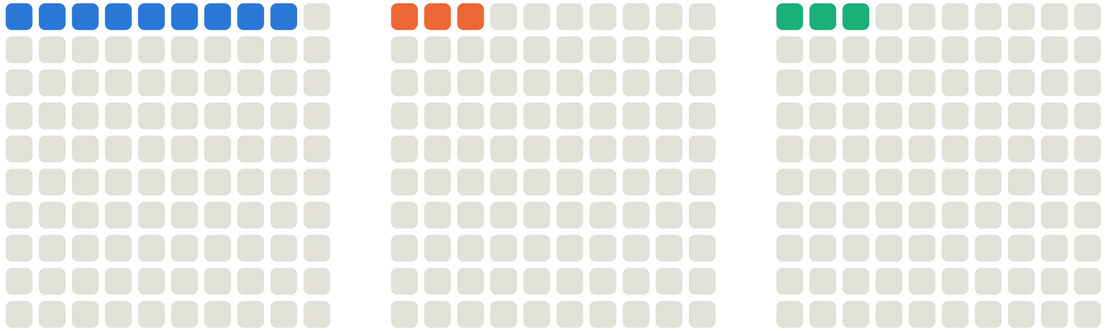
9,1 % con coste

Edificios

3,5 % con coste

Contenidos

3,1 % con coste

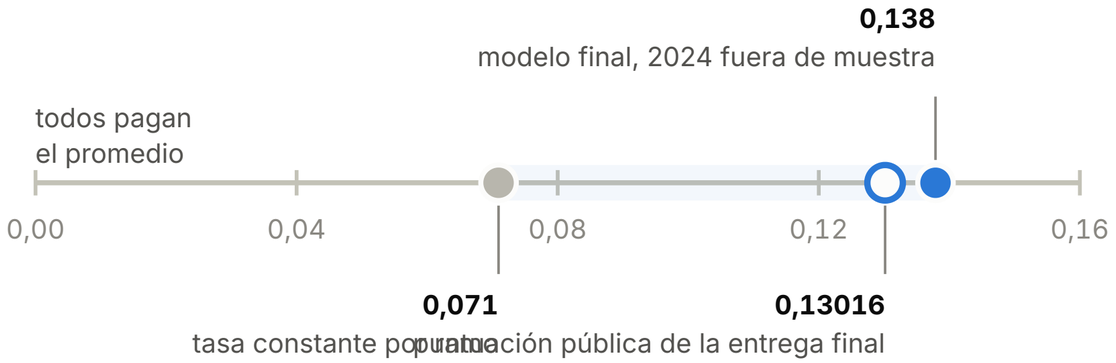


Cada cuadro es un periodo de póliza de 2024; los coloreados tuvieron coste.

Cómo se mide: D^2 Tweedie, potencia 1,5

D^2 = 1 – desviación del modelo / desviación del promedio

Desviación Tweedie con potencia 1,5, sumada sobre todos los periodos



La escala llega a 1 solo si se acertara el coste exacto de cada periodo.

Seis etapas, cada una comprobada

El retraso de reporte entra una sola vez, por la exposición de entrenamiento. Las etapas 4 a 6 se validan con años completos fuera de muestra.



Datos: corregir lo demostrable, declarar lo que no

Los once archivos originales no se tocan. Ocho reglas reversibles dejan bitácora por fila, y una reconstrucción independiente coincidió en 148 millones de celdas.

Problema encontrado	Filas	Tratamiento
Claves de cliente de autos sin sus ceros iniciales	123.664	Relleno a ocho dígitos; cruce recuperado
Exposición guardada en días o en base 360	14.229	Días cubiertos / 365
Capitales que saltan cerca de ×1000	2.073 + 1.454	Divididos entre mil; 149 sin confirmación histórica
Siniestros duplicados	604	Se excluye la copia
Renovaciones rechazadas, siniestros previos al historial	12.041 · 413	Solo marcas de auditoría, nunca predictores

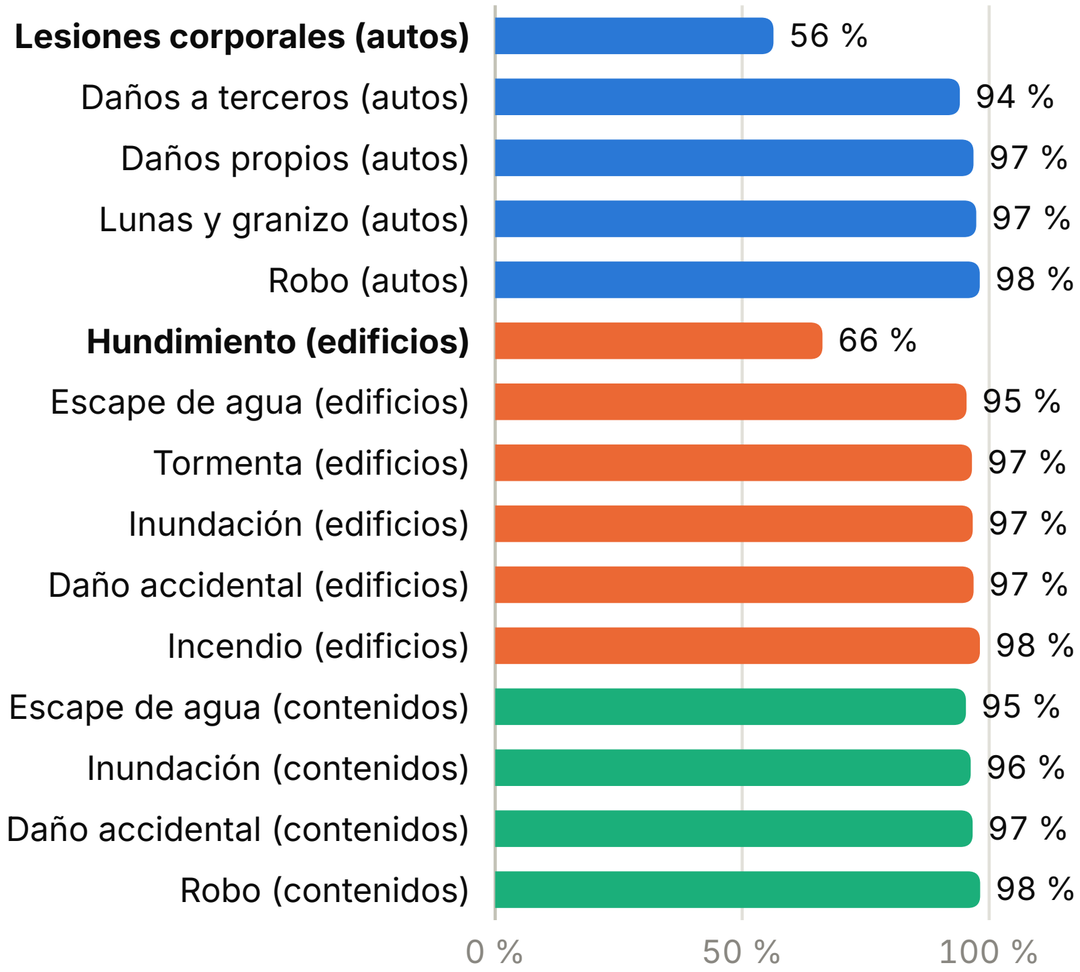


incluye 90,2 M CU de reservas de caso

Parte de los siniestros de 2024 aún no se conocía

Un chain-ladder de conteos por peligro estima qué parte de la exposición de 2024 ya está «vista». Dos peligros destacan.

Parte de la exposición de 2024 ya reportada, por peligro



Cómo entra el retraso en el modelo

Lesiones de autos, exposición nominal 2024	**1,00**
× parte de sus siniestros ya reportada	**0,56**
= exposición efectiva, el offset del entrenamiento	**0,56**
Exposición para predecir 2025	**nominal**

El modelo aprende la tasa del año completo con los siniestros ya vistos, así que el IBNR no se suma dos veces. El hundimiento de edificios está en 66 %; los demás peligros, entre el 94 y el 98 %.

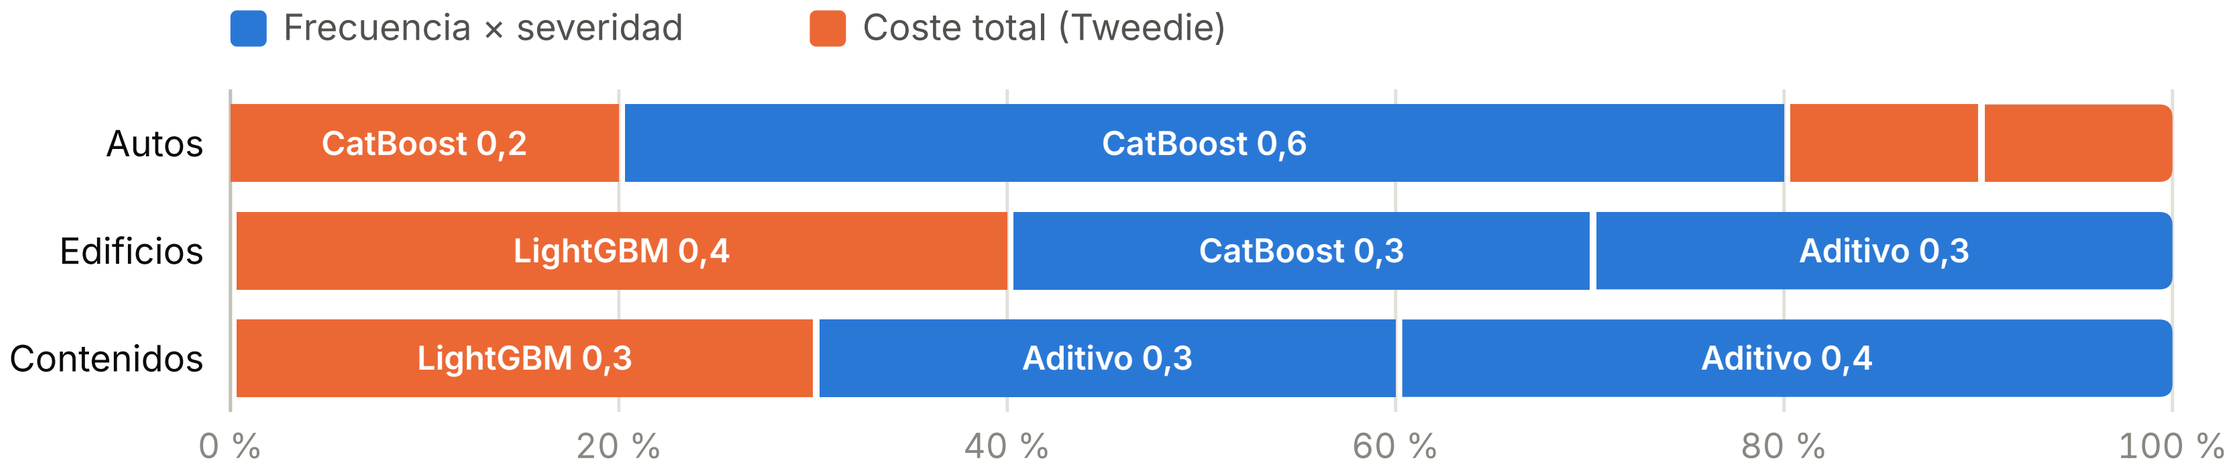
Con el IBNR, 2024 deja de ser una anomalía

Prima de riesgo de autos por año-exposición: 454 CU observados en 2024, 584 con el IBNR estimado y 592 en la predicción final de 2025.



La Mezcla por peligro: un modelo, diez componentes

Cada ramo mezcla modelos Tweedie del coste total con frecuencia × severidad por peligro. Los cambios se juzgaron en 2023 y 2024, con todas las pérdidas y sin las más extremas, según criterios escritos antes de calcular.



594,6 CU

Autos: prima de riesgo media 2025 por año-exposición

Factor de nivel 0,996 (2023: 0,986 · 2024: 1,005)

Tendencia de severidad por peligro, acotada a ±15 %

Entrega final: ×0,996 → 592,3 CU

495,0 CU

Edificios: prima de riesgo media 2025 por año-exposición

Factor de nivel 1,097 (2023: 1,059 · 2024: 1,134)

Tendencia de severidad por peligro, acotada a ±15 %

Entrega final: ×1,026 → 507,8 CU

124,5 CU

Contenidos: prima de riesgo media 2025 por año-exposición

Factor de nivel 1,085 (2023: 1,078 · 2024: 1,092)

Sin tendencia de severidad

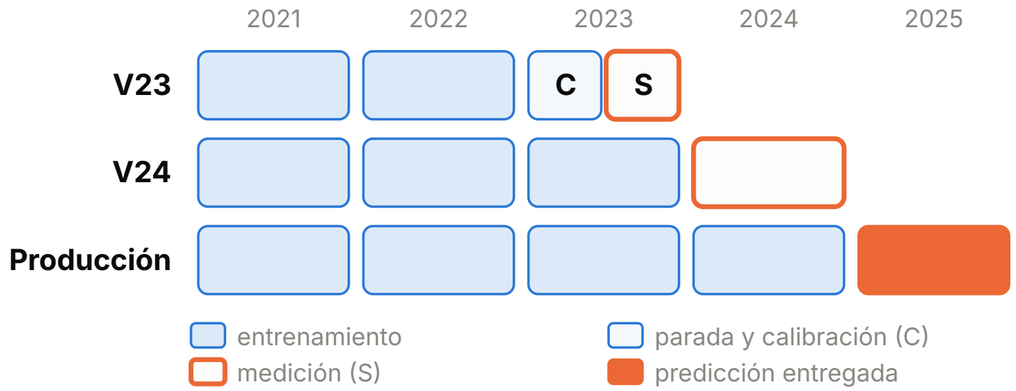
Entrega final: ×1,013 → 126,1 CU

Nivel 2025 por ramo: f = Σ(y/√μ) / Σ√μ, el factor que minimiza la desviación Tweedie, promediado entre los cortes de 2023 y 2024; la entrega final lo recalibra (lámina 15).

Ajustado con años pasados, medido en un año posterior

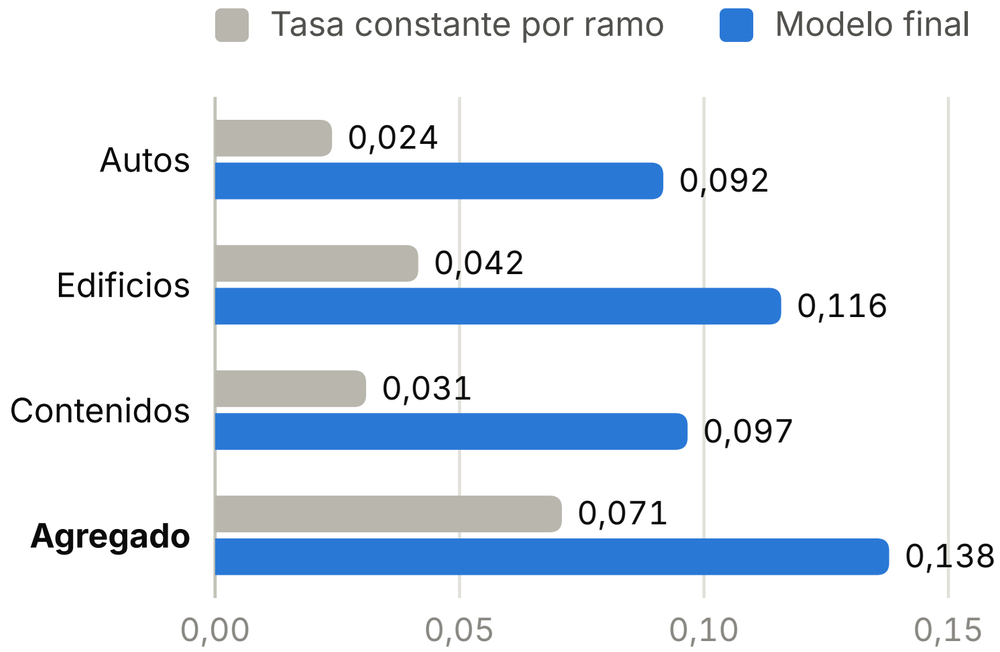
En 2024 el modelo final explica casi el doble de desviación que una tasa constante por ramo (0,138 frente a 0,071) y mejora cada ramo.

Tres cortes temporales



C y S: mitades de clientes de 2023 para calibrar y para medir.
Etiquetas valoradas al 31-12-2024: validación temporal aproximada.

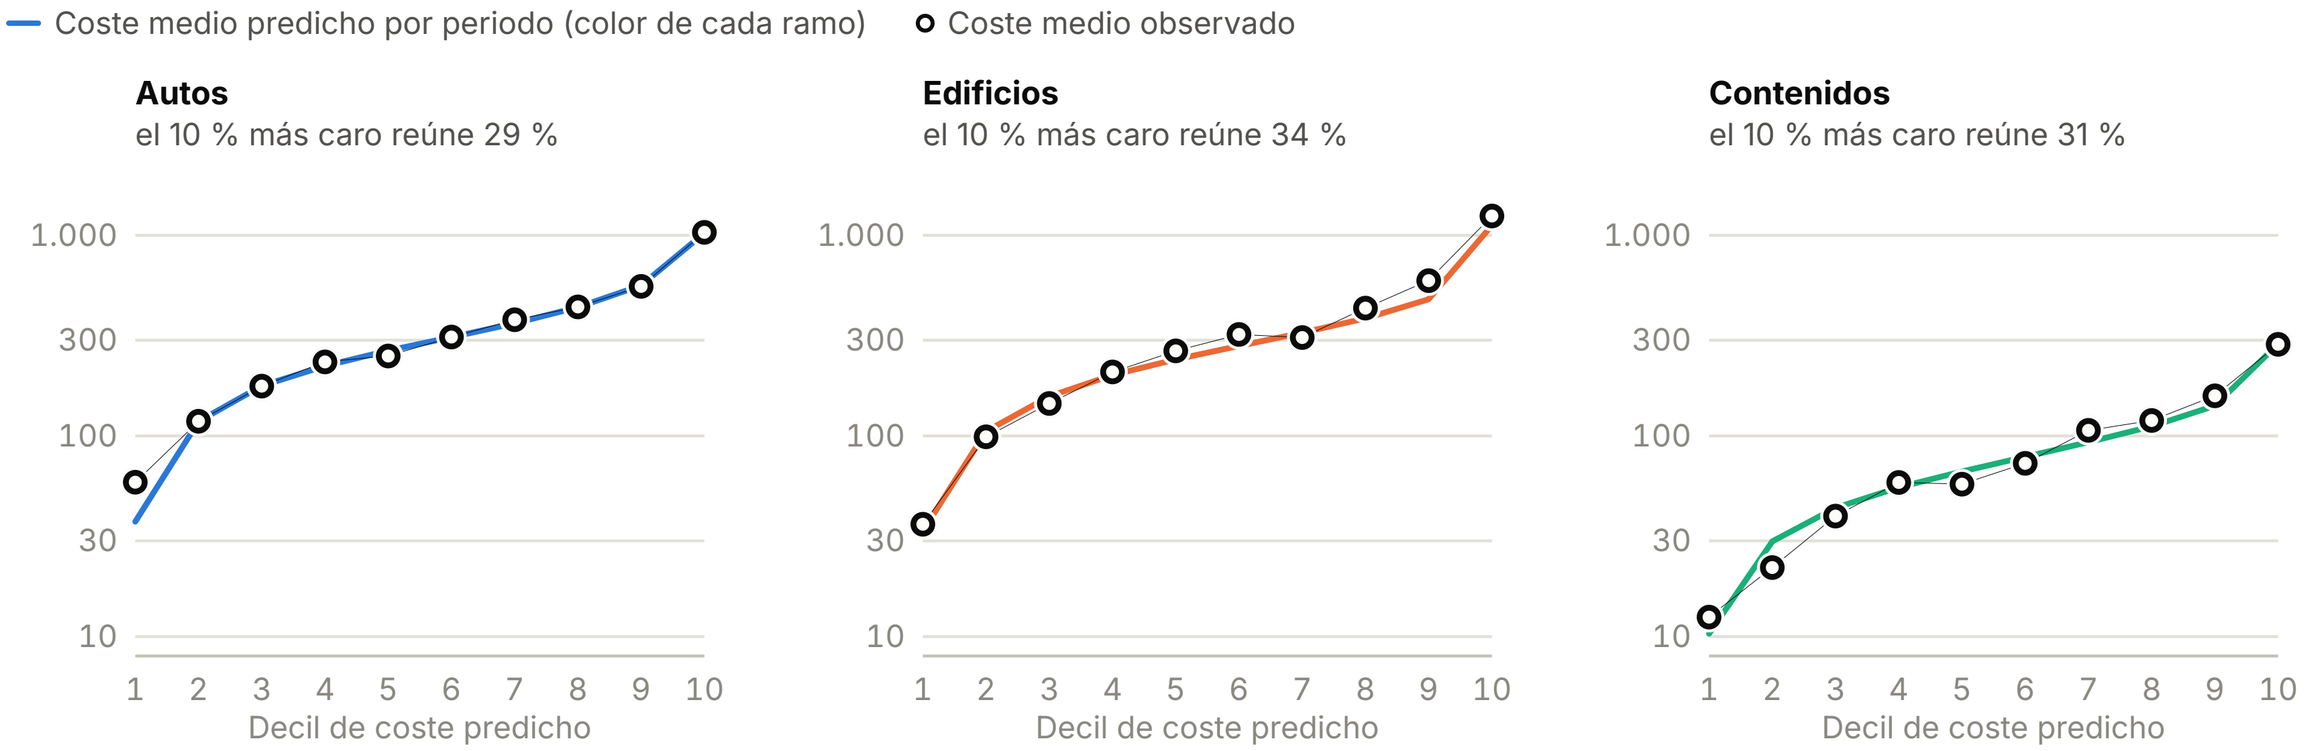
D^2 de 2024 por ramo



Tras la elección, once experimentos preinscritos, entre ellos un backtesting del IBNR, volvieron a poner a prueba el modelo; el informe detalla cada uno con su resultado.

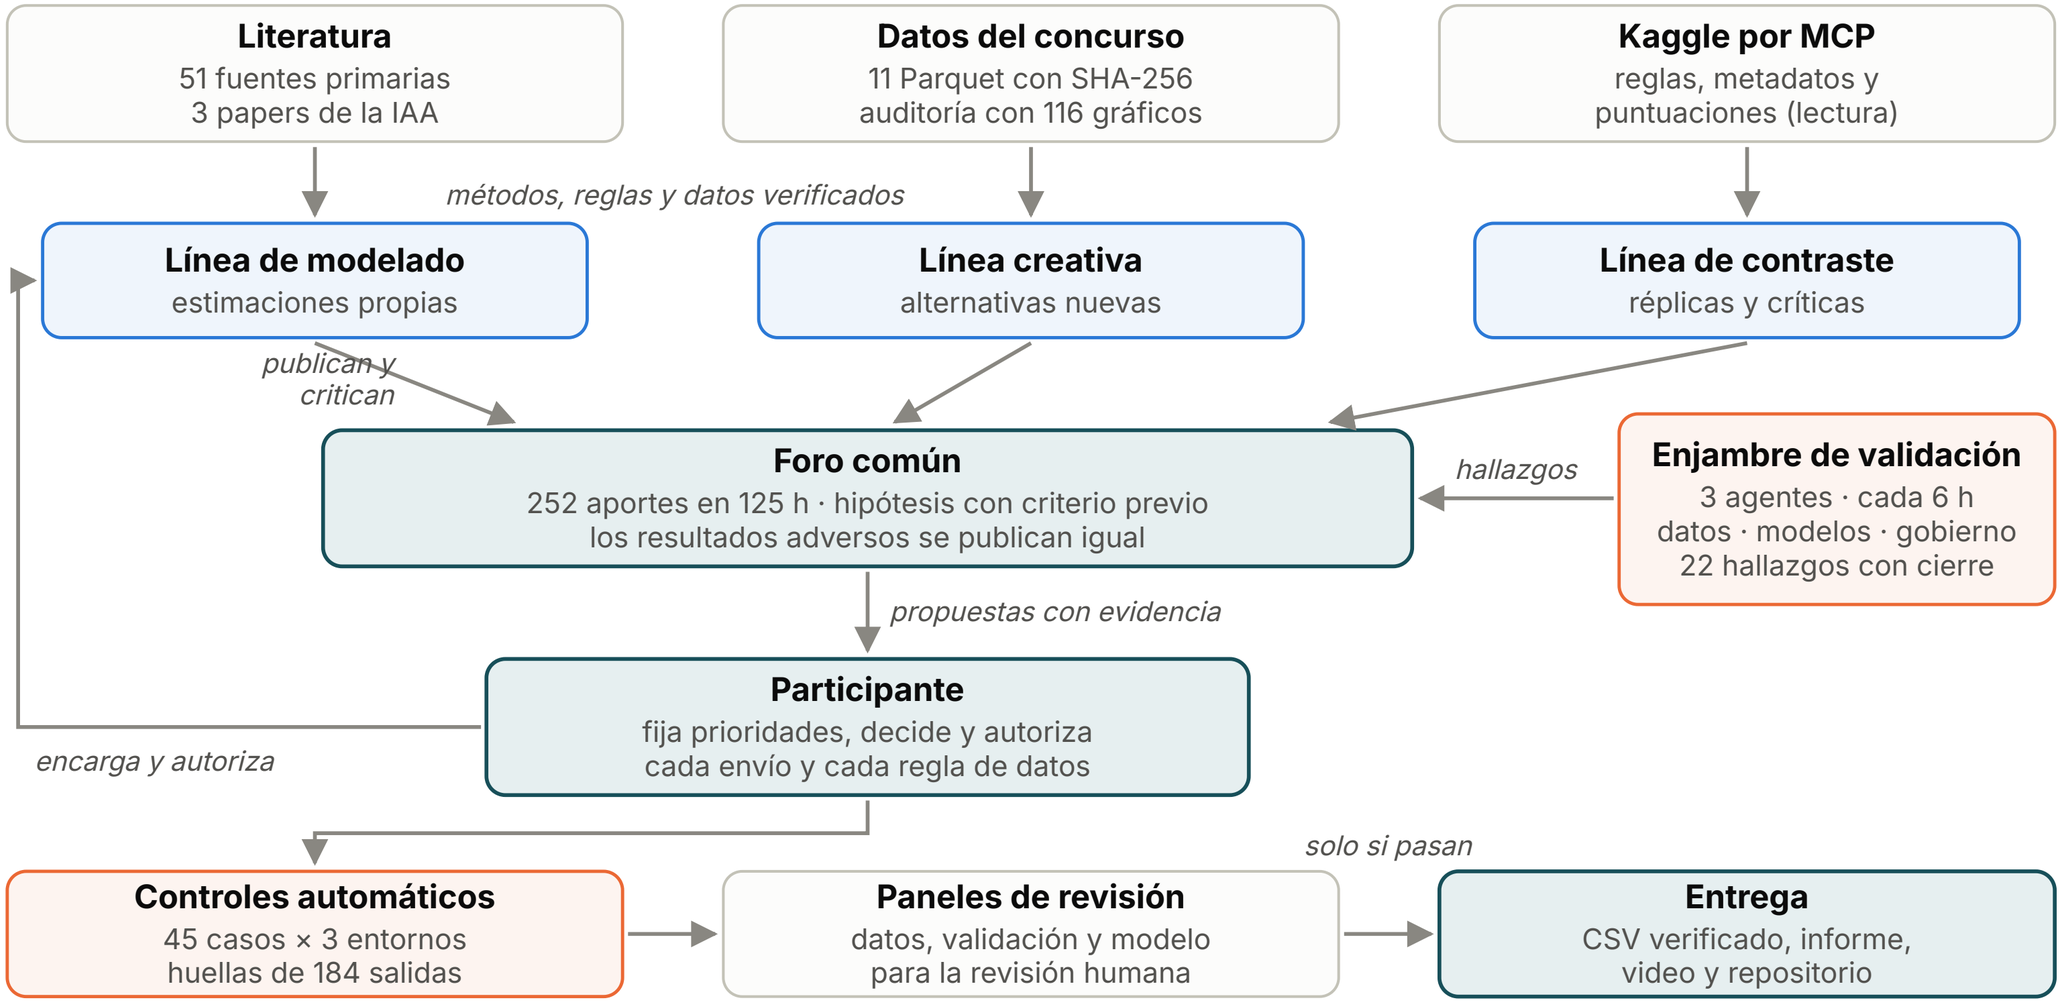
Ordena el riesgo y se mantiene calibrado

El 10 % de periodos con mayor coste predicho reúne el 29–34 % del coste observado en 2024. Con reservas de caso ×0,75 o ×1,25, el D^2 solo pasa de 0,1379 a 0,1372, mientras el nivel de 2025 se mueve hasta un 6,8 %.



La IA se organizó para que una línea contrastara a otra

Dos asistentes, Claude y Codex, en tres líneas. Las hipótesis se publicaban con su criterio de aceptación antes de calcular, y los resultados adversos también.



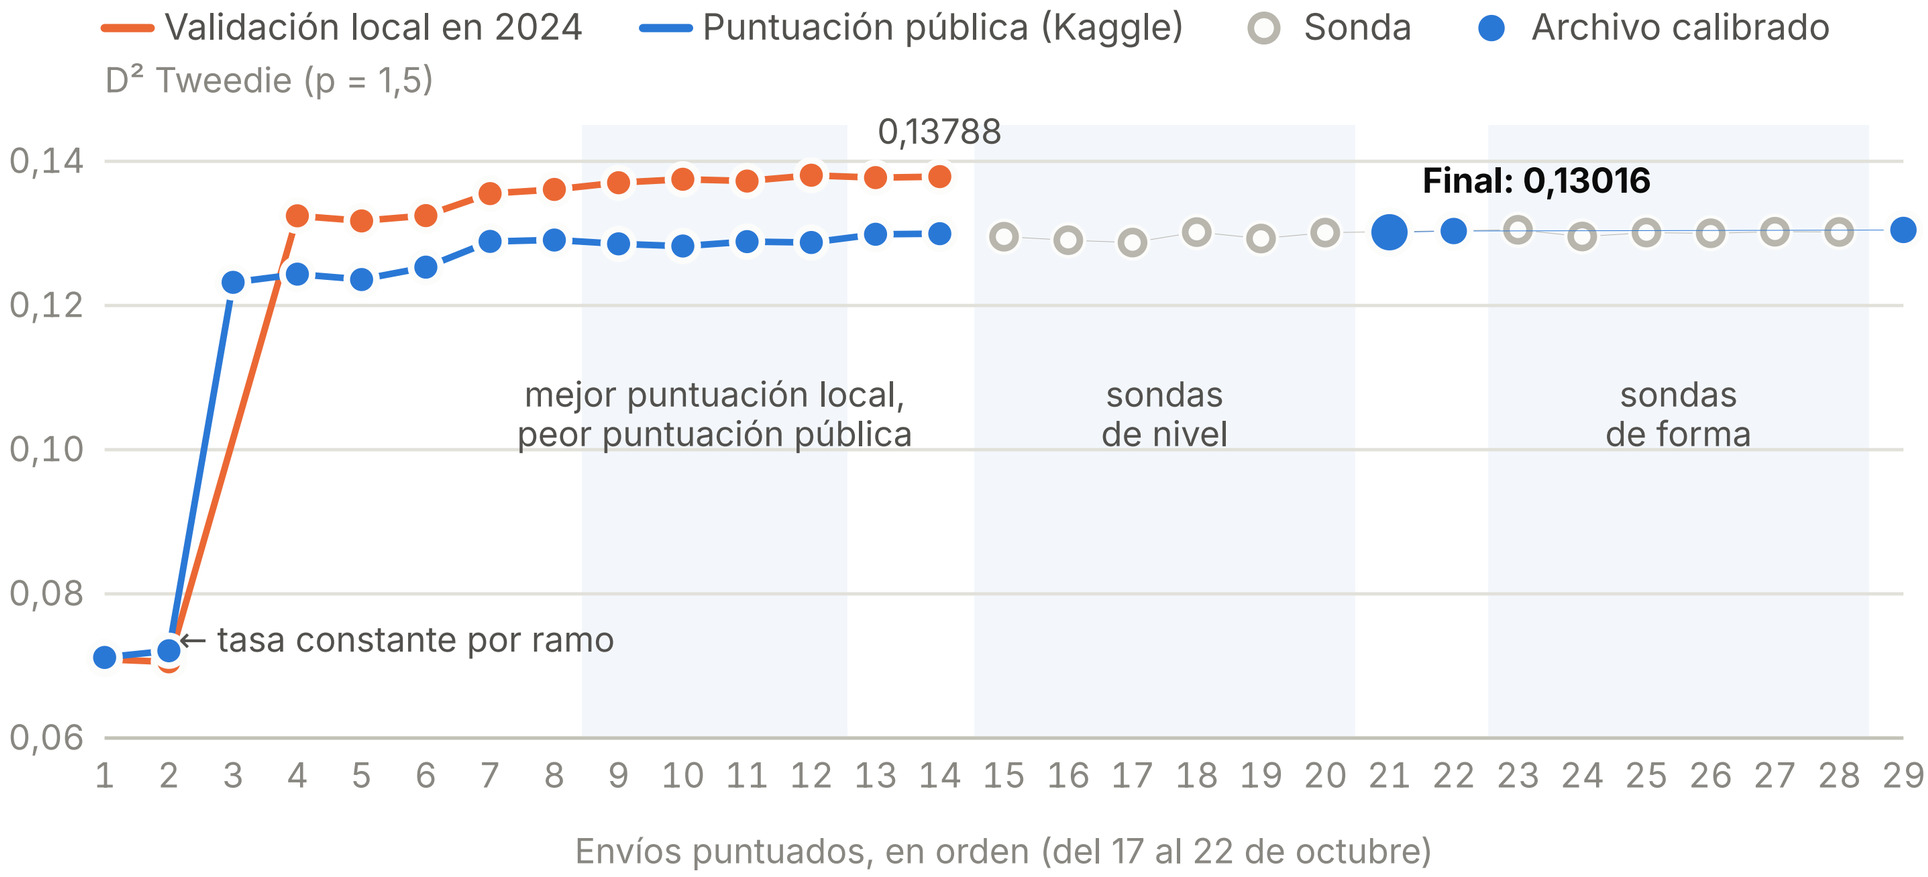
Qué hizo la IA en cada etapa y cómo se comprobó

Cada etapa tuvo su propia comprobación, y las decisiones que llegaron al modelo pasaron por mi autorización.

Etapa	Qué hizo la IA	Cómo se verificó
Datos y objetivo	Auditó 105 columnas con 174 controles; encontró los ceros perdidos, la exposición en días, los capitales ×1000 y 604 duplicados	Recálculo independiente (41/41) y reconstrucción idéntica byte a byte
Variables	Contrato de disponibilidad por columna; detectó una variable que mide el propio siniestro del periodo (D^2 0,43; las demás, menos de 0,04)	Excluida en código por una guardia de predictores
Metodología	Dos búsquedas: 51 fuentes primarias cotejadas con DOI y arXiv, más tres papers de la IAA	Se descartaron afirmaciones sin soporte, como una mejora del 17 % propuesta por otra herramienta de IA
Contexto del concurso	Reglas, metadatos y puntuaciones leídos de Kaggle por una conexión MCP, solo lectura	Cada recibo de envío guardado con la huella de su CSV
Modelado	44 contrastes numerados en la línea de contraste y preinscripciones en las otras dos	Intervalos por grupos de cliente, dirección y región; escenarios de reserva
Calibración del nivel	Forma cerrada de la puntuación pública en el factor de nivel, su ruido por bootstrap y una regla de credibilidad escrita antes de las sondas	Kaggle devolvió la puntuación prevista hasta el quinto decimal; una batería posterior favoreció el archivo de la regla
Pruebas y gobierno	Orquestador de 30 nodos con huellas de 184 salidas; enjambre de validación	Un validador vio que el paquete podía declarar éxito con archivos faltantes: se corrigió y se probó con 36 casos adversos

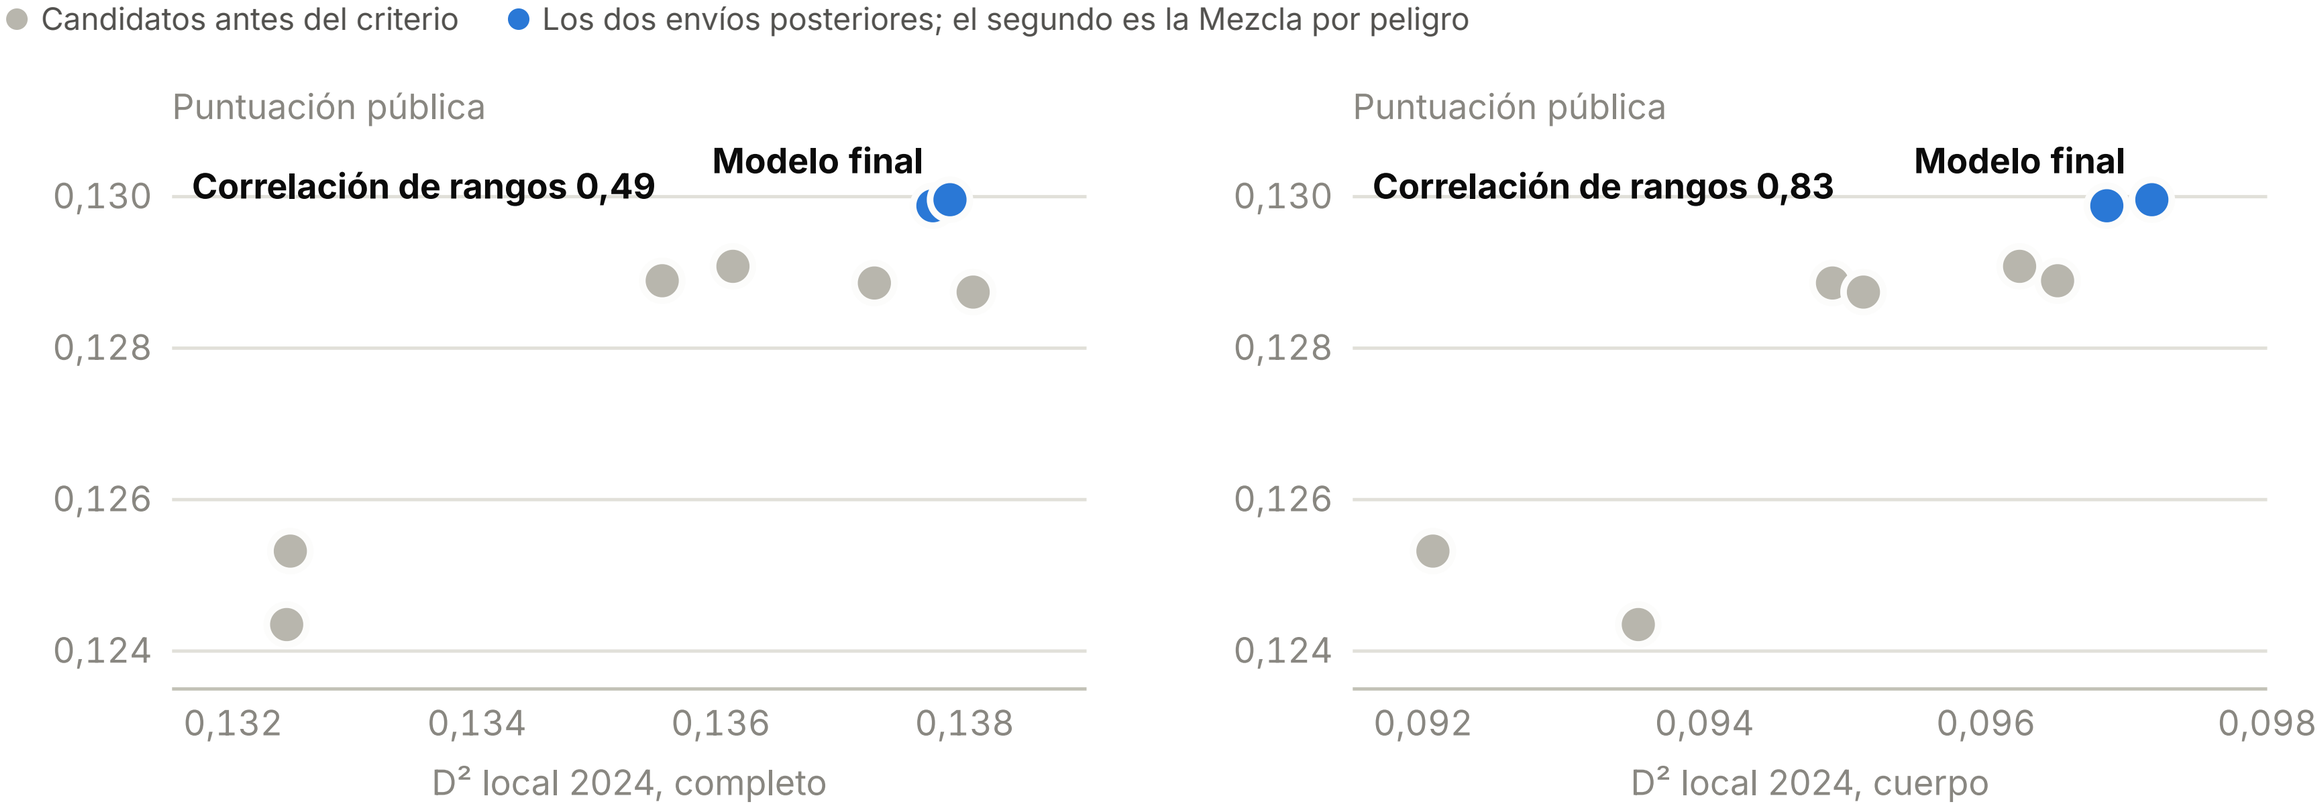
Lo que mejoraba en local no mejoraba en público

Los 29 envíos puntuados, en orden. En la primera zona sombreada la puntuación local de 2024 seguía subiendo mientras la pública bajaba, y el foro se propuso explicar por qué; la segunda reúne las seis sondas de nivel, y después vienen S41 y calibraciones posteriores que se probaron y no se eligieron.



El foro propuso juzgar el cuerpo sin sacar la cola

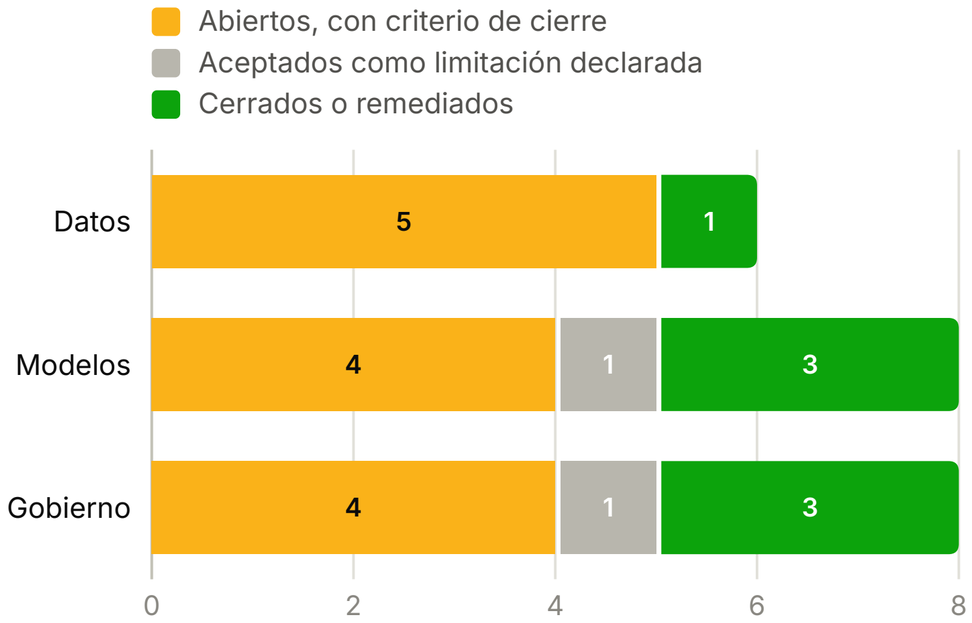
Unos pocos siniestros extremos movían la puntuación local. Sin el 0,5 % de periodos más costosos, el D² local ordena como la puntuación pública (correlación de rangos 0,83 frente a 0,49). Los dos envíos que siguieron marcaron el máximo público de la búsqueda de modelos.



Un enjambre de agentes auditó el proyecto cada 6 horas

Tres agentes, de datos, modelos y gobierno, levantaron 22 hallazgos. Cada uno indica cómo se cierra y qué revisor humano necesita.

Hallazgos por área y estado



Severidad alta · Cerrado por mi decisión, solo en su alcance técnico

Los controles del paquete permitían éxito con incumplimientos

Corregido en código y probado con 36 casos adversos; la independencia y las reservas siguen como limitaciones declaradas.

Severidad alta · Documentos corregidos y verificados

Exclusión causal excesiva de la insuficiencia de reservas

La afirmación sobre las reservas se rebajó a hipótesis.

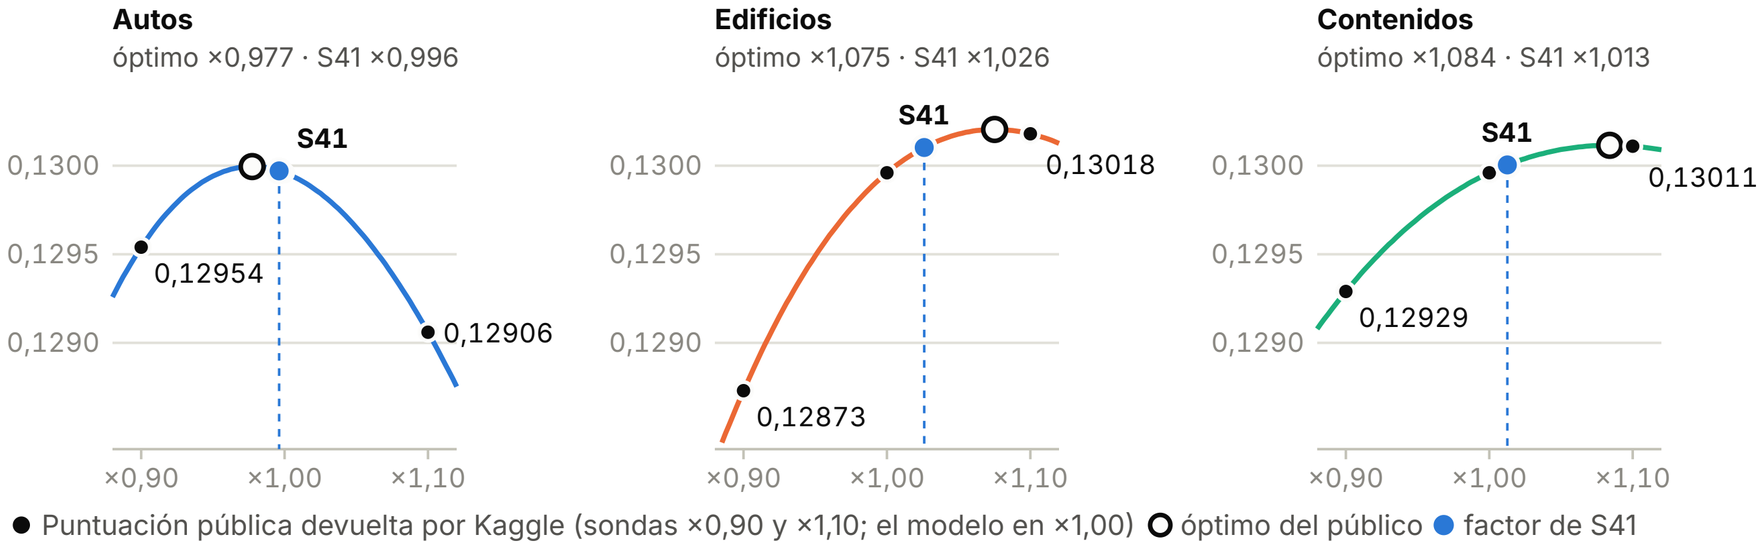
Severidad alta · Abierto

Disponibilidad al cotizar sin acreditar en variables condicionadas y clima anual

Requiere que el dueño de los datos confirme las fechas.

El nivel de 2025: tres factores leídos del tablero público

Dos sondas por ramo trazaron la puntuación pública en forma cerrada. Una regla de credibilidad fijada antes de mirar dio S41, la entrega final, que puntuó lo previsto hasta el quinto decimal; no se reentrenó nada.



Ramo	Óptimo público	Credibilidad Z, regla fijada antes	Factor de S41	Evidencia sin el tablero	Lectura
Autos	×0,977	0,17	×0,996	Coinciden los efectos de etiqueta (−1,55 %); no el último año (+0,92 %) ni la siniestralidad de 2024 (+0,95 %)	Parcial
Edificios	×1,075	0,35	×1,026	Coinciden el último año (+3,44 %) y la siniestralidad de 2024 (+3,23 %), tamaño dentro	Apoyado
Contenidos	×1,084	0,15	×1,013	Coinciden los tres (+0,68 %, +0,03 %, +1,94 %), tamaño dentro	Apoyado

Ganancia esperada en el privado frente a la mezcla con el ruido corregido, bajo tres pares de previas: +0,000019, +0,000062, +0,000083; S41 es el único archivo calibrado que supera a la mezcla con los tres. El criterio de evidencia se escribió antes de calcular; comparte los datos del proyecto y no es validación profesional.

Los archivos entregados se pueden regenerar y comprobar

45 de 45 casos de control pasan en la nube, en una máquina virtual y en Windows. El CSV de la mezcla se reconstruye desde componentes guardados con el SHA-256 que recibió Kaggle, y S41 a partir de él con los tres factores.

Capa	Resultado
Datos originales y reconstrucción	11 de 11 idénticos; 0 diferencias en 148 M de celdas
Objetivo y exposición	18 de 18 controles
Variables	25 de 25 controles
Paquete: 9 casos nominales y 36 adversos	45 de 45 en tres entornos
CSV entregados: la mezcla y S41	10 de 10 controles en cada uno

```
$ python reproducir.py mezcla --objetivo=S30

recibo Windows · 19 oct 2026
CSV final mismo SHA-256 que recibió Kaggle
intermedios diferencia relativa máx. 7,2e-16
código de salida 3 = CSV idéntico, intermedios tolerados

$ python reproducir.py todo --objetivo=S30

recibo nube de referencia · 20 oct 2026 · 36 nodos
CSV final mismo SHA-256 que recibió Kaggle
intermedios 162 de 181 iguales; máx. 3,9e-15
réplica 436 estimadores sin reajuste: 194 de 194
idénticas

$ python herramientas/regenerar_s41.py

CSV de S41 mismo SHA-256 que recibió Kaggle
controles 10 de 10 controles de entrega
```

Un panel sin conexión, docs/entrega/panel_modelo.html, muestra cada cifra con la tabla que la sostiene, en español o inglés.

Lo que aún no podemos demostrar y cómo lo probaremos

Once experimentos preinscritos, entre ellos un backtesting del IBNR, midieron estos límites; el informe da a cada uno su efecto o la comprobación que lo cerraría.

Límites que declaramos

- Con una sola valoración no se puede demostrar la suficiencia de las reservas: un error del 4,4 % en las de autos ya mueve el nivel de S41 un 1 %.
- El nivel de 2025 se calibró con un tercio del test; sin el tablero, la evidencia apoya edificios y contenidos, y autos solo en parte.
- 2023 y 2024 eligieron el modelo, y su ventaja sobre el mejor envío anterior no es robusta.
- Las fechas de las variables al cotizar aún necesitan la confirmación del dueño de los datos.
- 149 capitales divididos pesan el 0,01 % del total, pero deciden sus propias filas.
- El reentrenamiento y la réplica los hizo el mismo flujo, no un operador independiente.

Protocolo de la semana 2 para el mercado nuevo

Qué compararemos	Respuesta prevista
Contrato, unidades y exposición	Reconstruir la capa preparada
Mezcla de peligros y colas	Reajustar severidades; revisar el criterio del cuerpo
Desarrollo de siniestros	Reestimar el chain-ladder
Variables disponibles	Actualizar el contrato y la guardia de predictores
Rendimiento del modelo congelado	Recalibrar primero el nivel, con sondas, una previa fijada antes y el ruido medido en la parte no vista; reconstruir solo si hace falta

En el repositorio: docs/entrega/ (informe, panel, láminas) · reproducir.py · docs/expediente/ (foro, decisiones y recibos)